

CAP. 2 APRESENTAÇÕES ESTATÍSTICAS

A massa de dados, tal como resulta do processo de amostragem, não permite a visualização de qualquer característica da amostra levantada e muito menos da população que originou a amostra.

As tabelas e os gráficos são recursos estatísticos que resumem, organizam e apresentam grandes quantidades de dados, tornando-os compreensíveis ao pesquisador, já que tornam “visíveis” as várias informações neles contidas.

2.1 Apresentação tabular de dados

Os dados são apresentados em tabelas, também chamados quadros. Existem normas para a apresentação de tabelas. As tabelas devem apresentar *título*, *corpo* e *cabeçalho*. O título deve preceder à tabela e designar o dado em estudo, indicando as condições em que foi obtido. O corpo da tabela é formado pelo conjunto de linhas e colunas onde os dados estão colocados. O cabeçalho deve especificar o conteúdo das colunas. Toda a tabela deve ter o corpo delimitado, em cima e em baixo, por linhas horizontais. As colunas podem ser separadas, para maior clareza, por linhas verticais. O cabeçalho é separado dos dados por um traço horizontal.

Os pesquisadores são naturalmente livres em formatar a tabela “a gosto próprio” desde que obedeçam os requisitos básicos antes descritos.

2.1.1 Tabelas de distribuição de frequências

1 Dados brutos: São aqueles que ainda não foram organizados, ou seja, encontram-se tal como foram registados.

2 Rol: Um rol é um arranjo de dados numéricos em ordem crescente ou decrescente de grandeza.

3 Amplitude total: A diferença entre o maior e o menor número do rol. Por exemplo, se a maior altura de um grupo de 50 estudantes do sexo masculino é 188 cm e a menor 152 cm, a amplitude total será de $188 - 152 = 36$ cm.

Os dados relativos a uma variável quantitativa podem ser resumidos e apresentados numa *tabela de distribuição de frequências*.

Distinguem-se fundamentalmente os seguintes tipos de tabelas de distribuição de frequência:

1. Tabela de distribuição de frequências simples
2. Tabela de distribuição de frequências de classes
 - 2.1 Tabela de distribuição de frequências de **classes pré - definidas**
 - 2.2. Tabela de distribuição de frequências de **classes a definir**

1 - Tabelas de distribuição de frequências simples

Primeiro, arranjam-se os valores observados em ordem crescente, ou seja, transformam-se os dados brutos em um rol de dados. Organizam-se de seguida três colunas e escreve-se na primeira coluna, **uma única vez** e em ordem crescente, cada valor observado. Na segunda coluna e na linha correspondente a cada valor observado, escreve-se o número de vezes que este valor se repete no conjunto de dados, ou seja, a respectiva **frequência absoluta**. A terceira coluna destina-se às frequências relativas com que cada valor ocorre na amostra.

$$\text{Frequência relativa (\%)} = \frac{\text{frequência absoluta}}{\text{tamanho da amostra (n)}} \times 100$$

Além da frequência absoluta e da frequência relativa, pode ser ainda calculada a frequência acumulada, que pode ser determinada somando-se a frequência observada para esta classe com a frequência acumulada da classe precedente.

Exemplo: Distribuição do tempo de serviço de 100 trabalhadores de uma empresa.

Tempo de serviço (anos) (X)	N.º de trabalhadores (frequência absoluta, f)	Frequência relativa (fr)	Frequência acumulada
18	50	50 %	50
19	20	20 %	50+20=70
22	10	10 %	70+10=80
24	10	10 %	80+10=90
26	10	10 %	90+10=100

Exemplo: Idade de candidatos inscritos para os exames de acesso à Faculdade de Ciências da Universidade Agostinho Neto nos anos académicos 2008 e 2009.

Tab. 1A: Distribuição de **frequências simples** das idades dos indivíduos amostrados

N.º de Indivíduos		
Idade	2008	2009
16	45	6
17	142	24
18	365	131
19	458	217
20	672	223
21	605	256
22	507	240
23	431	207
24	320	129
25	198	92
26	152	74
27	91	31
28	64	31
29	55	15
30	51	19
31	31	11
32	18	11
33	8	4
34	20	6
35	11	3
36	12	2
37	8	1
38	6	2
...	...	...

Tab. 1B: Distribuição de **frequências de classes** das idades dos indivíduos amostrados (intervalo de classe convencional de 10 Anos)

Indivíduos		
Idade	2008	2009
15-25	3744	1525
25-35	501	205
35-45	48	16
45-55	3	3
55-65	2	0
Total	4298	1749

A tabela 1A, de distribuição de frequências simples, mostra a sua inadequação para os propósitos de resumir grandes quantidades de dados. A tabela é excessivamente longa na vertical (porque têm que ser listados todos os valores amostrados, do menor ao maior valor) e acima de tudo, **não permite a leitura das características dos dados**. Já a tabela 1B, que agrupa os valores em classes, resume **de facto** os dados e permite uma leitura interpretativa das características do conjunto. Assim, já se pode “ler”, por exemplo, que a maior parte dos indivíduos candidatos ao ingresso na Faculdade de Ciências, tanto em 2008 como em 2009, tem uma idade entre 15 e 25 anos.

2 - Tabelas de distribuição de frequências de classes

Quando se pretende resumir grandes massas de dados brutos, costuma-se frequentemente distribuí-los em *classes* ou *categorias* e determinar o número de indivíduos pertencentes a cada uma das classes, denominado *frequência da classe*.

As tabelas de distribuição de frequência de classes permitem uma visualização mais rápida das características da distribuição da variável. No entanto, é importante escolher bem o número de classes, de maneira a dar ênfase às características do fenómeno.

Um número pequeno de classes geralmente resulta em uma perda de informação e um número muito grande de classes evidencia pormenores desnecessários.

Para a determinação do número de classes estão descritos na literatura vários critérios. A maior parte dos autores ^(1,6,10,12,13,19) enfatiza o uso de critérios de fundamento matemático para a definição do número de classes.

Milton & Tsokos (1991) indicam o uso das seguintes fórmulas para a determinação do n.º de classes:

$$1 - n.^{\circ} \text{ de classes} = 5 \times \lg n \quad \text{em que } n \text{ é o tamanho da amostra}$$

$$2 - n.^{\circ} \text{ de classes} = \sqrt{n}$$

Beiguelman (2002) indica que *“o n.º de classes é frequentemente tomado entre 8 e 20, dependendo dos dados”*.

Beth & Trapp (2003) sugerem que, *“em geral, entre 6 e 14 classes são o número adequado para o fornecimento de informações suficientes sem ocorrer o excesso de detalhes”*. Adiantam ainda que *“existem várias regras disponíveis para o cálculo do número de classes, mas o bom senso em geral é adequado para se tomar essa decisão”*.

Triola & Triola (2006) recomendam que o número de classes deve situar-se entre 5 e 20 enquanto Kuzma & Bohnenblust (2001) são de opinião que o número de classes deve ser de 5 a 15.

No entanto, muitas variáveis (nas ciências biológicas, nas ciências tecnológicas, nas ciências económicas e sociais, etc.) têm categorias já definidas e com indicação dos respectivos valores de referência, isto é, estão padronizadas.

Esta categorização / padronização, já existente, **é o critério mais adequado** para a construção das tabelas de distribuição de frequências para estas variáveis, **porque associa os valores das categorias aos respectivos atributos qualitativos que caracterizam, finalmente, os indivíduos**. Ao contrário disto, as classes (categorias) calculadas com recurso aos critérios de fundamento matemático são desprovidas de significado porque não se associam a nenhum atributo qualitativo dos indivíduos. A associação entre as categorias, os seus valores de referência e os respectivos atributos qualitativos é, **no entanto**, fundamental para os usuários, porque permite a interpretação inequívoca dos resultados dos levantamentos de dados.

O critério acima referido fundamenta a diferenciação das tabelas de frequência de classes nos dois tipos já referidos:

- Tabelas de distribuição de frequências de **categorias pré - definidas**
- Tabelas de distribuição de frequências de **categorias por definir**

2.1 - Tabelas de distribuição de frequências de categorias pré - definidas

No acto de inscrição de candidatos a exame de acesso à Faculdade de Ciências da Universidade Agostinho Neto, nos anos 2008 e 2009, foram colectados dados de várias variáveis, de entre elas o peso e a altura dos indivíduos.

Os dados sobre o peso e a altura dos indivíduos amostrados servem de base para a construção do Índice de Massa Corporal (IMC). O IMC ajuda a definir o grau de obesidade de uma pessoa segundo a Organização Mundial da Saúde. Através do cálculo e interpretação do IMC é possível saber se uma pessoa está acima ou abaixo dos parâmetros de peso ideal ou saudável para a sua estrutura.

Já que o objectivo é avaliar a relação peso / altura, expressa em IMC, nos indivíduos, para poder-se afirmar se os indivíduos são ou não obesos ou se têm ou não um peso convenientemente relacionado com as respectivas estruturas, **o critério válido para a construção da tabela de distribuição de frequências** é o uso dos valores de referência, padronizados e certificados pela comunidade científica mundial através da Organização Mundial da Saúde (ver página 1.13, Capítulo 1)

Tabela 2: Distribuição do IMC dos indivíduos amostrados.

		N.º de Indivíduos	
Condição	IMC	Ano 2008	Ano 2009
Abaixo do peso	< 19,9	1286	497
Peso Normal	20 – 24,9	2396	1025
Obesidade leve	25 – 29,9	508	186
Obesidade moderada	30 – 39,9	99	41
Obesidade mórbida	> 40	9	0

A interpretação dos dados representados torna-se óbvia pela associação dos atributos quantitativos (IMC) aos qualitativos (Condição).

A tabela 2 mostra que a maior parte dos indivíduos amostrados, tanto em 2008 como em 2009, tem peso normal. Constata-se também que, felizmente, o número de indivíduos com obesidade mórbida (e por isso com maior risco de saúde) é muito baixo em 2008 e inexistente em 2009.

A tensão arterial é também uma variável com categorias pré-definidas.

Quadro nº 1 - Classificação da hipertensão arterial segundo as cifras tensionais, de acordo com o VII relatório da Joint National Committee.

Classificação da pressão arterial	Pressão arterial sistólica (mmHg)		Pressão arterial diastólica (mmHg)
Normal	< 120	e	< 80
Pré-hipertensão	120 á 139	ou	80 á 89
Hipertensão estágio 1 (grau I)	140 á 159	ou	90 á 99
Hipertensão estágio 2 (grau II)	≥ 160	ou	≥ 100

Fonte: Modificado de Chobanian AV, Bakris GL, Black HR et al. The seventh report of the Joint National Committee on prevention, detection, evaluation, and treatment of high blood pressure. JAMA 2003; 289:2560-72. Citada em *Pedrosa e Drager, 2010*.

A tabela 3 ilustra a distribuição da tensão arterial medida nos candidatos ao exame de acesso à faculdade de ciências da Universidade Agostinho Neto nos anos 2008 e 2009.

Tabela 3: Distribuição dos indivíduos segundo os valores da tensão arterial sistólica.

Indivíduos						
Classificação	TA Sistólica		2008		2009	
Normal	0	120	1680	39%	511	29%
Pré-hipertenso	121	139	1917	45%	856	49%
Hipertenso grau I	140	159	611	14%	344	20%
Hipertenso grau II	160	240	90	2%	38	2%
			4298	100%	1749	100%

Este tipo de leitura interpretativa da tabela de distribuição de frequência (do ponto de vista dos usuários da informação, por exemplo doentes ou pessoas que queiram informar-se sobre o seu estado de saúde no âmbito de um *check-up*, profissionais da saúde, etc.) é dificultado quando se usam apenas os critérios de fundamento matemático, como se pode constatar na tabela a seguir, extraída de Pagano e Gauvreau (2004).

Tabela 4: Frequências absolutas dos níveis séricos de colesterol para 2.294 homens dos Estados Unidos, 1976 – 1980.

Nível de colesterol (mg/100 ml)	Número de Homens	
	Idade 25 - 34	Idade 55 - 64
80 - 119	13	5
120 - 159	150	48
160 - 199	442	265
200 - 239	299	458
240 - 279	115	281
280 - 319	34	128
320 - 359	9	35
360 - 399	5	7

Fonte: Pagano e Gauvreau, 2004.

A tabela 4 não possibilita a ligação entre as classes e os respectivos atributos qualitativos da variável, ou seja, o significado do valor do colesterol. A qualquer indivíduo que faça uma análise de sangue ou outra qualquer, pouco interessa o valor obtido. **O que interessa mesmo é saber se está bem ou está doente.** Esta resposta é dada pelo profissional de saúde que faz a ligação entre o quantitativo e o qualitativo, usando os valores de referência para a variável em questão.

Ao fazer-se uso dos valores padronizados para o Colesterol (página 1.12, capítulo 1), nota-se que a tabela 4 tem classes supérfluas, já que estão desprovidas de qualquer significado. A classe que estabelece o ponto de corte é a que está destacada a negrito, com os valores 200 – 239. Esta é a classe ou categoria que agrupa todos os indivíduos com colesterol limítrofe, i.e., tolerável. Todas as classes acima desta, ou seja com valores inferiores a 200, agrupam indivíduos “iguais” em termos de níveis séricos de colesterol, ou seja, são normais ou têm os níveis desejados. Procede-se de igual maneira para todas as classes com valores acima de 239.

A tabela 4 ficaria resumida nas seguintes três categorias facilmente interpretáveis.

Tabela 5: Frequências absolutas dos níveis séricos de colesterol para 2.294 homens dos Estados Unidos, 1976 – 1980.

	Nível de colesterol (mg/100 ml)	Número de Homens	
		Idade 25 - 34	Idade 55 - 64
Desejável ou Normal	< 200	605	318
Limítrofe	200 - 239	299	458
Alto	≥ 240	163	451

Fonte: Pagano e Gauvreau, 2004; modificada usando as categorias padronizadas.

A tabela 5 é de fácil leitura por qualquer pessoa, já que estabelece claramente a ligação entre as classes e os respectivos atributos qualitativos da variável, ou seja, o significado do valor do colesterol. Assim, pode-se ver que nos homens amostrados com idade de 25 a 34 anos predominam taxas de colesterol normais, enquanto na maior parte dos homens com idade superior, os níveis de colesterol são mais elevados, ocupando as categorias limítrofe e alto.

2.2 - Tabelas de distribuição de frequências de classes por - definir

Nos casos em que as variáveis não têm categorias pré-definidas deve-se procurar na literatura informações que sirvam de base para a definição de categorias. Na maior parte dos casos o objectivo será definir pelo menos as três categorias mais comuns: médio, alto, baixo ou ainda normal, acima do normal e abaixo do normal.

Exemplo:

Idade de 182 candidatos inscritos para os exames de acesso aos cursos da Faculdade de Ciências da Universidade Agostinho Neto, no ano académico 2009. A média da idade é de 22 anos e o desvio padrão é de 4 anos.

No caso actual as categorias serão criadas a partir do intervalo de variação de GAUSS que é dado: $22 \pm 4 = (18 - 26)$. Considera-se então que este é o intervalo que indica a idade média dos candidatos aos exames de acesso. Acima de 26 a idade é considerada alta e abaixo de 18 é considerada baixa. O limite superior da classe “alta” e o limite inferior da classe “baixa” podem ser fixados aleatoriamente, desde que abarquem o maior e o menor valor dos dados brutos e que são o 46 e o 16 respectivamente.

Veja a resolução completa na página 3 do manual “Estatística em Excel”.

DICAS - Como fazer uma leitura interpretativa de uma tabela de frequências.

1. Destaque em primeiro lugar as categorias com maior e menor frequência.
2. Dê ênfase às outras categorias só se elas se afigurarem interessantes, tendo em conta o carácter da variável.

Evite fazer leitura de “cima a baixo” passando por todas as categorias. Corre-se o risco de evidenciar pormenores supérfluos.

Use de preferência as frequências relativas.

2.2 Apresentação gráfica de dados

Os gráficos facilitam a visualização da importância relativa de categorias e de classes. Todo gráfico deve apresentar *título* e *escala* dispensando esclarecimentos adicionais no texto. O título é geralmente colocado abaixo do gráfico. As escalas devem crescer da esquerda a direita e de baixo para cima e devem existir setas indicativas da direção dos eixos. Também devem ser indicadas as variáveis representadas em cada eixo (titular os eixos). Esta indicação também pode ser feita na extremidade de cada eixo.

A escala deve iniciar na origem do sistema de eixos cartesianos ou deve ser feita uma nítida interrupção no eixo, com indicação clara da posição do zero. Os eixos do sistema cartesiano e as demais linhas auxiliares devem ter traçado leve em relação à parte do gráfico que pretendemos evidenciar. As legendas explicativas, que se fizerem necessárias, devem ser colocadas à direita do gráfico.

2.2.1 Histogramas e polígonos de frequência

São duas representações gráficas de distribuições de frequência.

1. Um *histograma* ou *histograma de frequência* consiste em um conjunto de triângulos (barras) que tem:

(a) as bases sobre um eixo horizontal (eixo dos X) em que são colocados os limites de classe.

(b) no eixo vertical as frequências (absolutas ou relativas) de classe.

Se todos os intervalos tiverem a mesma amplitude, as alturas dos rectângulos serão proporcionais às frequências das classes e, então, costuma-se tomar as alturas numéricas iguais a essas frequências.

As barras devem ser justapostas, evidenciando a natureza contínua dos dados.

A figura 2.1 mostra um histograma feito para a distribuição de frequências dos dados da tabela 2.1.

Tabela 2.1: Distribuição de frequências do tempo de aparição da reacção alérgica a pacientes após picada de abelhas (pontos médios de classe) *exemplo fictício*

Classe	Limites de classe (tempo)	Ponto médio de classe (X_c)	Frequência (n.º de pacientes)
1	3,75 – 5,95	4,85	2
2	5,95 – 8,15	7,05	4
3	8,15 – 10,35	9,25	10
4	10,35 – 12,55	11,45	16
5	12,55 – 14,75	13,65	6
6	14,75 – 16,95	15,85	2




Fig. 2.1: Histograma para a distribuição de frequências do tempo de aparição da reacção alérgica.

Tab. 2.2: Número médio de acidentes em empresas de um certo ramo da indústria.
(frequência relativa e proporções acumuladas ou frequência relativa acumulada)

Número médio de acidentes (Xi)	Número de empresas (f)	Frequência relativa (fr)	Proporção acumulada
1,45 – 1,75	3	0,06	0,06
1,75 – 2,05	12	0,24	0,30
2,05 – 2,35	14	0,28	0,58
2,35 – 2,65	9	0,18	0,76
2,65 – 2,95	7	0,14	0,90
2,95 – 3,25	5	0,10	1,00
Total 50		Total 1,00	




Fig. 2.2: Histograma para a distribuição de frequência relativa da tabela 2.4.

Um *polígono de frequência* é um gráfico de linha de uma distribuição de frequência. Os eixos deste gráfico são similares aos de um histograma, excepto que no eixo horizontal são colocados os pontos médios de cada classe. O número de observações em cada classe é representado por um ponto acima do ponto médio da classe, sendo tais pontos ligados por uma série de segmentos de recta formando uma “figura de muitos lados”, ou polígono. Geralmente acrescentam-se segmentos que vão ter aos pontos médios imediatamente inferior e superior e cujas frequências são nulas (subtracção e adição da amplitude de classe ao ponto médio inferior e superior da distribuição de frequência).




Fig. 2.3: Polígono e curva de frequência para os dados da tabela 2.3.




Um polígono “suavizado” é denominado **curva de frequência**.

2.2.2 Curvas de frequência

Curvas de frequência aparecem, na prática, sob diversas formas características. Elas diferem em termos de assimetria e curtose.

Em termos de assimetria, uma curva de frequência pode ser (ver também secção 3.1.5):


- a) simétrica: tem a forma de sino. Caracteriza-se pelo facto da média, mediana e moda não diferirem em termos de valor. Um exemplo importante é a *curva normal*.
- b) assimétrica negativa: assimétrica com a “cauda” para a esquerda
- c) assimétrica positiva: assimétrica com a “cauda” para a direita



Fonte: Kazmier (1982)

Em termos de curtose (arqueação, abaulamento), uma curva de frequência pode ser:

- (1) *platicúrtica* ; achatada, com as observações distribuídas de modo relativamente uniforme entre as classes;
- (2) *leptocúrtica* pontiaguda, com as observações concentradas em um pequeno intervalo de valores; ou
- (3) *mesocúrtica*; nem achatada nem pontiaguda, em termos de valores observados.



Fonte: Kazmier (1982)

2.2.3 Curva de frequência acumulada. Ogivas

O gráfico de uma distribuição de frequência acumulada é conhecido como *ogiva*. Quando tal gráfico é suavizado, recebe o nome de *curva ogiva*.

Ogivas percentuais

A frequência acumulada relativa ou percentual é a frequência acumulada dividida pela total. Por exemplo, a frequência acumulada relativa das alturas abaixo de 174,5 (tabela 2.1) é de $65/100 = 65\%$, o que significa que 65% dos estudantes tem alturas inferiores a 174,5 cm. Se nas tabelas e figuras forem utilizadas frequências acumuladas relativas, em vez das próprias acumuladas, os resultados seriam denominados *distribuições de frequência acumulada relativa* ou *percentual* e *polígono de frequência acumulada relativa* ou *ogivas percentuais*.




Fig. 2.4: Ogiva e curva ogiva para os dados da tabela 2.3.

2.2.4 Diagrama de barras e gráficos de linha

O *diagrama de barras* ou *diagrama de colunas* representa, por meio de uma série de barras, quantidades ou frequências para diferentes categorias de dados. A diferença entre um diagrama de barras e um histograma reside em que o segundo refere-se sempre aos dados de uma distribuição de frequências, enquanto o primeiro ilustra quantidades para qualquer tipo de categorias.

Um *diagrama de barras ou de colunas por componentes* retracts subdivisões dentro das barras ou das colunas do diagrama.

Sempre que as categorias utilizadas representarem um intervalo de tempo, os dados podem ser descritos também através de um *gráfico de linha*.




Fig. 2.5 Distribuição do n.º de pacientes internados num Hospital por ano e por patologia.

2.2.5 Gráficos circulares (Tartes)

O diagrama de sectores é um gráfico particularmente apropriado para representar as divisões de um universo total.

Em um diagrama de sectores de percentagens os valores são convertidos em percentagens com o fim de facilitar as comparações.




Fig. 2.6: Distribuição do n.º de pacientes internados num hospital, por patologias, durante um certo tempo.

Exercício

Os dados a seguir referem-se aos níveis de ácido úrico, em mg/100 ml, encontrados nos exames bioquímicos de sangue de pacientes seropositivos seguidos no Hospital Esperança em Luanda, no ano 2012.

4,99	4,59	4,45	6,61	4,63	0,53	3,67	3,27	3,39	3,25	4,47	4,48	5,00	6,60	5,20
3,14	3,43	3,77	3,23	7,08	9,09	7,08	11,30	7,22	2,88	4,92	6,54	7,57	3,89	3,96
2,71	3,80	2,78	2,89	5,75	2,43	3,44	2,62	2,12	6,80	5,08	3,45	5,39	5,29	5,05
5,35	2,47	6,17	10,20	9,82	5,33	4,51	4,87	4,80						

1. Classificar a variável em níveis de medida;
2. Construir a tabela de frequências dos níveis de ácido úrico dos pacientes amostrados;
3. Calcular as frequências relativas e interpretar os dados;
4. Construir uma tabela de frequências para os valores do ácido úrico, usando critérios de fundamento matemático. Faça a interpretação dos resultados.
5. Compare as duas tabelas e respectivas interpretações. Que conclui?