

CAP. 3

DESCRIÇÃO DE DADOS CARACTERÍSTICAS AMOSTRAIS

3.1 Medidas de tendência central

Os dados relativos a uma variável quantitativa, apresentados em uma tabela, dão visão geral do problema em estudo. Entretanto, é extremamente conveniente proceder a uma descrição de dados através de medidas que mostrem, de maneira bastante concisa, certas características da amostra.

As medidas de tendência central, também chamadas medidas de localização ou de posição, estabelecem o valor em torno do qual os dados se distribuem. Tratam-se de valores típicos ou representativos de um conjunto de dados que tendem a localizar-se em um ponto central, dentro de um conjunto de dados ordenados segundo as suas grandezas.

Serão analisadas as seguintes medidas de tendência central: média aritmética, mediana e moda.

3.1.1 Média aritmética

A média aritmética, que é representada por $\bar{X}$ (lê-se X-barra), é definida como a soma dos valores de todos os dados dividida pela soma dos valores.

Nota: Em estatística, uma medida descritiva de uma população, ou seja um parâmetro populacional, é geralmente representado por uma letra grega enquanto que uma medida descritiva de uma amostra, ou seja uma estatística amostral, é representada por uma letra romana.

A média aritmética para uma população é representada pelo símbolo μ (lê-se mu).

As fórmulas de cálculo para as médias de uma população e da amostra são:

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{\sum X}{n} \quad (3.1)$$

$$\mu = \frac{\sum X}{n} \quad (3.2)$$

Exemplo 3.1: Considere uma família com cinco filhos ($n = 5$) tendo as seguintes idades em anos: 8, 3, 5, 12, 10

A média aritmética desta amostra é

$$\bar{X} = \frac{8 + 3 + 5 + 12 + 10}{5} = \frac{38}{5} = 7,6$$

Interpretação: A média da idade dos filhos desta família é 7,6 anos (ou seja 8 anos).

Se os números $X_1, X_2, \dots, X_n$ ocorrem $f_1, f_2, \dots, f_n$ vezes (ou seja ocorrem com as frequências $f_1, f_2, \dots, f_n$) a média aritmética será:

$$\bar{X} = \frac{X_1.f_1 + X_2.f_2 + \dots + X_n.f_n}{f_1 + f_2 + \dots + f_n} = \frac{\sum f.X}{\sum f} \quad (3.3)$$

onde $n = \sum f$, frequência total, (i.e. o total do n.º de dados).

Exemplo 3.2: considere uma turma com 10 alunos, dos quais 3 têm 5 anos, 2 têm 6 anos, 4 têm 8 anos e 1 tem 2 anos.

Idade (X_i)	5	6	8	2
n.º de alunos (f_i)	3	2	4	1

$$\bar{X} = \frac{5.3 + 6.2 + 8.4 + 2.1}{3 + 2 + 4 + 1} = \frac{15 + 12 + 32 + 2}{10} = 4,1$$

Interpretação: a média da idade dos alunos desta turma é de 4 anos.

A média aritmética para dados agrupados

Quando os dados se encontram agrupados em classes em uma distribuição de frequência, o ponto médio de cada classe é utilizado como uma aproximação de todos os valores contidos na classe. O ponto médio é representado pelo símbolo X_c , onde o subscrito c indica a classe, sendo o símbolo f utilizado para representar a frequência de valores observados em cada classe respectiva. Assim, as fórmulas para as médias da população e da amostra, são, para o caso de dados agrupados:

$$\mu = \frac{\sum (f.X_c)}{\sum f} \quad (3.4)$$

$$\bar{X} = \frac{\sum (f.X_c)}{\sum f} \quad (3.5)$$

Operacionalmente, as duas fórmulas indicam que cada ponto médio de classe (X_c) é multiplicado pela respectiva frequência de classe (f), somando-se os produtos, e sendo então, a soma dividida pelo número total de observações representadas na distribuição de frequência.

Tabela 3.1: Distribuição de frequências do tempo de aparição da reacção alérgica a pacientes após picada de abelhas (pontos médios de classe).

Tempo de aparição da reacção alérgica (min.)	Ponto médio de classe (X_c)	N.º de pacientes (f)	f X_c
3,75 – 5,95	4,85	2	9,7
5,95 – 8,15	7,05	4	28,2
8,15 – 10, 35	9,25	10	92,5
10,35 – 12,55	11,45	16	183,2
12,55 – 14,75	13,65	6	81,9
14,75 – 16,95	15,85	2	31,7

$$\Sigma = 427,2$$

$$\bar{X} = \frac{\sum (f \cdot X_c)}{n} = \frac{427,2}{40} = 10,68$$

3.1.2 Média aritmética ponderada

As vezes, associam-se os números $X_1, X_2, \dots, X_n$ a certos factores de ponderação ou pesos $P_1, P_2, \dots, P_n$ que dependem do significado ou importância atribuída aos números. Isto significa que cada valor se encontra ponderado de acordo com a sua importância no grupo total.

Nesse caso

$$\bar{X}_p = \frac{X_1 \cdot P_1 + X_2 \cdot P_2 + \dots + X_n \cdot P_n}{P_1 + P_2 + \dots + P_n} = \frac{\sum (X \cdot P)}{\sum P} \quad (3.6)$$

tem a denominação de média aritmética ponderada.

Note-se a semelhança com a fórmula (3.3), que pode ser considerada uma média ponderada com os pesos $f_1, f_2, \dots, f_n$.

Exemplo 3.3: Se o exame final, em um curso, tem peso 3 e as provas parciais peso 1 e um estudante tem nas provas parciais as notas 10 e 11 e no exame final a nota 15, a sua média ponderada será:

$$\bar{X}_p = \frac{(10 \cdot 1) + (11 \cdot 1) + (15 \cdot 3)}{1 + 1 + 3} = \frac{66}{5} = 13,2$$

Compare: média não ponderada $\bar{X} = 12,0$

3.1.3 A mediana

A mediana (representada por $\tilde{X}$) de um conjunto de números, ordenados em ordem de grandeza (crescente ou decrescente) é o valor médio ou a média aritmética dos dois valores centrais.

Para se obter a mediana deve-se, portanto, em primeiro lugar ordenar os dados brutos da amostra de forma crescente ou decrescente.

Depois, se o número de dados é ímpar, a mediana é o valor que ocupa a posição central dos dados ordenados.

Exemplo 3.4: O conjunto dos n.ºs 3, 4, 4, 5, 6, 8, 8, 8, 10 (9 dados) tem mediana 6.

Se o número de dados é par, a mediana é o valor da média aritmética dos dois valores que ocupam a posição central dos dados ordenados.

Exemplo 3.5: O conjunto dos n.ºs 5, 5, 7, 9, 11, 12, 15, 18 (8 dados) tem mediana $\tilde{X} = \frac{(9+11)}{2} = 10$

Quando se está em presença de um grande número de dados as fórmulas seguintes são usadas para determinar a posição da mediana no grupo ordenado:

Para n ímpar: $\text{Med.} = X_{\frac{n+1}{2}}$ (3.7)

Note: a expressão $(n+1)/2$ é o índice de X , i.e., a mediana é a observação $X_{\frac{n+1}{2}}$

Para n par: $\text{Med} = \frac{X_{\frac{n}{2}} + X_{\frac{n}{2}+1}}{2}$ (3.8)

Exemplo 3.6: Usando os dados dos exemplos 3.4 e 3.5.

$\text{Med} = X_{\frac{9+1}{2}} = X_5$ mediana é a observação $X_5 = 6$ dos dados ordenados.

$\text{Med} = \frac{X_{\frac{8}{2}} + X_{\frac{8}{2}+1}}{2} = \frac{X_4 + X_5}{2} = \frac{9+11}{2} = 10$ nos dados ordenados: $X_4 = 9$; $X_5 = 11$

A Mediana para dados agrupados

- 1.º Determinar a classe que contem o valor mediano.
Esta é a classe cuja frequência acumulada iguala ou excede a metade do n.º total de observações ($n/2$).
- 2.º Determinar o valor específico da mediana pela fórmula:

$$\tilde{X} = Li_{cm} + \left(\frac{\frac{n}{2} - F_{am}}{f_{cm}} \right) \cdot A_{cm}$$

cm Classe que contém a mediana

Li_{cm} Limite inferior da classe que contém a mediana

n Dimensão da amostra

F_{am}	Frequência acumulada da classe anterior à classe que contém a mediana
f_{cm}	Frequência absoluta da classe que contém a mediana
A_{cm}	Amplitude do intervalo da classe que contém a mediana

3.1.4 A Moda

A moda (representada por $\hat{X}$) é o valor que mais frequentemente ocorre em um conjunto de valores. No caso, a distribuição é descrita como sendo *unimodal*. Para pequenos conjuntos de dados, onde não há repetição de valores, não existe a moda. Quando dois valores, não adjacentes, são quase iguais em termos de frequências máximas, a distribuição é descrita como sendo *bimodal*. As distribuições de medidas com várias modas são chamadas distribuições *multimodais*.

Exemplo 3.7: O conjunto de dados 8, 11, 5, 14, 8, 11, 16 e 11 tem moda = 11.

A moda para dados agrupados

Determina-se a classe que contém a moda, identificando-se a classe com o maior número de observações. Alguns estatísticos consideram a moda como o ponto médio da classe modal. Todavia, a maioria dos estatísticos faz uma interpolação dentro da classe modal com base na seguinte fórmula:

$$\hat{X} = Li_{c\text{moda}} + \left(\frac{d_1}{d_1 + d_2} \right) \cdot A_c$$

$Li_{c\text{moda}}$ limite inferior da classe que contém a moda

d_1 diferença entre a frequência da classe modal e a frequência da classe precedente

d_2 diferença entre a frequência da classe modal e a frequência da classe seguinte

A_c Amplitude do intervalo de classe

3.1.5 Significado e importância das estatísticas amostrais média, mediana e moda

Para os dados agrupados representados por uma curva de frequência, as diferenças entre os valores da média, da mediana e da moda são indicadores da forma da curva em termos de assimetria. Para uma distribuição unimodal simétrica, a média, mediana e moda são todas coincidentes em valor. Para uma distribuição positivamente assimétrica, a média apresenta o valor mais elevado, enquanto a mediana é maior do que a moda mas menor do que a média. Para uma distribuição negativamente assimétrica, a média apresenta o menor valor, segue-se a mediana e por fim a moda com o valor mais elevado (ver também secção 2.2.2).




Fig. 3.1: Relação entre a média, mediana e moda. Fonte: Kazmier, 1982.

Simétrica: Média = Mediana = Moda

Assimétrica positiva: Média > Mediana > Moda

Assimétrica negativa: Média < Mediana < Moda

3.2 Medidas de variabilidade (dispersão)

As medidas de localização são úteis por identificarem um valor “típico” em um grupo de valores, em torno do qual os dados se distribuem.

Estas medidas são tanto mais apropriadas para descrever uma amostra quanto menor é a *dispersão* ou a *variabilidade* dos dados.

Para introduzir a ideia de dispersão, seja analisado o seguinte exemplo.

Supõem-se que a nota de aprovação em uma determinada disciplina é dada pela média aritmética das notas de 4 provas. Supõem-se ainda que 4 alunos desta disciplina obtiveram nas 4 provas as notas representadas na tabela seguinte:

Tab. 3.2: Notas dos alunos A, B, C e D em 4 provas.

	A	B	C	D
	5	6	10	0
	5	4	5	0
	5	4	5	10
	5	6	0	10
$\bar{X}$	5	5	5	5

Verifica-se que todos os alunos tiveram média 5, podendo se concluir que, em média, os alunos obtiveram a mesma nota.

Entretanto os dados permitem estabelecer as seguintes afirmações:

- as notas do aluno A não variaram
- as notas do aluno B variaram menos que as notas do aluno C
- as notas do aluno D são as que mais variaram

Estas afirmações podem ser verificadas através das medidas de dispersão. Serão estudadas a amplitude, o desvio médio, a variância e o desvio padrão.

As medidas de dispersão ou variação indicam o grau segundo o qual os dados numéricos tendem a dispersar-se em torno de um valor médio (de localização).

3.2.1 Amplitude

Por definição, a amplitude, que é representada por A , é a diferença entre o maior e o menor dado observado.

O cálculo da amplitude é muito simples, o que é um facto agradável e uma qualidade desejável. Entretanto, devemos frisar que a amplitude não é uma boa medida de dispersão porque o seu cálculo se baseia apenas nos valores extremos da amostra e não em todos os dados.

A amplitude para dados agrupados

Para dados agrupados em uma distribuição de frequências a amplitude total é geralmente definida como a diferença entre o limite superior da classe mais alta e o limite inferior da classe mais baixa.

3.2.2 Desvio médio

O desvio médio ou DM é baseado na diferença entre cada valor do conjunto de dados e a média do grupo. O que é calculado é a média destes desvios (alguns estatísticos usam a diferença entre cada valor e a mediana). Se fosse calculada a média das diferenças positivas e negativas entre cada valor e a média aritmética, o resultado iria ser de facto sempre igual a zero. Por esta razão, são tomadas as diferenças em *valores absolutos*.

$$\text{Na população:} \quad DM = \frac{\sum |X - \mu|}{N} \quad (3.9)$$

$$\text{Na amostra:} \quad DM = \frac{\sum |X - \bar{X}|}{n} \quad (3.10)$$

Exemplo 3.8: Os produtores de hortaliças de certa região produziram as seguintes quantidades (em toneladas) durante uma época: 8, 11, 5, 14, 8, 11, 16, 11 ($n = 8$, $\bar{X} = 10,5$)

Tab. 3.3: Folha de cálculos para determinar o desvio médio para os dados não agrupados.

X	(X - $\bar{X}$)	X - $\bar{X}$
5	-5,5	5,5
8	-2,5	2,5
8	-2,5	2,5
11	0,5	0,5
11	0,5	0,5
11	0,5	0,5
14	3,5	3,5
16	5,5	5,5

Total 21,0

$$DM = \frac{21,0}{8} = 2,625 \cong 2,6$$

Pode-se então dizer que, em média, a produção de hortaliças por agricultor difere por 2,6 toneladas da média aritmética do grupo.

O desvio médio para dados agrupados

Para dados agrupados em uma distribuição de frequência, o ponto médio de classe é tomado para representar todas as medidas incluídas na classe. Esta mesma abordagem é utilizada na determinação da média aritmética para dados agrupados.

$$\text{Na população: } DM = \frac{\sum (f | X_c - \mu |)}{N} \quad (3.11)$$

$$\text{Na amostra: } DM = \frac{\sum (f | X_c - \bar{X} |)}{n} \quad (3.12)$$

Exemplo 3.9: Seja X o tamanho (cm) de 30 plantas agrupados em uma distribuição de frequência. Calcular o desvio médio (média = 145,1 cm).

Tab. 3.4: Folha de cálculo para determinar o desvio médio para dados agrupados.

Limites	Ponto médio de classe	Frequência	$ X_c - \bar{X} $	$(f X_c - \bar{X})$
129,5 – 135,5	132,5	2	12,6	25,2
135,5 – 141,5	138,5	7	6,6	46,2
141,5 – 147,5	144,5	10	0,6	6,0
147,5 – 153,5	150,5	8	5,4	43,2
153,5 – 159,5	156,5	3	11,4	34,2

$$\Sigma = 154,8$$

$$DM = \frac{154,8}{30} = 5,2$$

Interpretação: O tamanho das plantas difere em média por 5,2 cm da média do grupo.

3.2.3 A variância e o desvio padrão

A variância é similar ao desvio médio no sentido de que é também baseada nas diferenças entre cada valor do conjunto de dados e a média aritmética do grupo. Ela difere do desvio médio uma vez que aquelas diferenças são elevadas ao quadrado antes de serem somadas.

A variância é um dos indicadores de variabilidade mais conhecidos e é frequentemente citado em vários trabalhos. No entanto, pelo facto dos seus resultados serem obtidos somando-se valores elevados ao quadrado, a Variância expressa a variabilidade dos dados como uma grandeza também ao quadrado (por exemplo a variância das alturas de um grupo de pessoas, medidas em centímetros, será expressa em cm^2).

Encontra-se solução para este problema extraindo a raiz quadrada da variância, obtendo-se assim um outro indicador de variabilidade, denominado **Desvio Padrão**.

Para uma população, a variância é representada pela letra grega minúscula σ^2 (ler sigma quadrado), sendo a fórmula:

$$\sigma^2 = \frac{\sum (X - \mu)^2}{N} \quad (3.13)$$

Ao contrário da situação para outras estatísticas amostrais que foram discutidas, a variância para uma amostra não é, em termos computacionais, exactamente equivalente à variância populacional. Antes, o denominador da fórmula da variância da amostra é ligeiramente diferente. Essencialmente, é introduzido um factor de correcção nesta fórmula, de tal maneira que a variância da amostra seja um estimador não tendencioso da variância da população. A variância da amostra é representada por S^2 , e sua fórmula é:

$$S^2 = \frac{\sum (X - \bar{X})^2}{n - 1} \quad (3.14)$$

Nota: Em alguns textos, o denominador da fórmula anterior é “n” e não “n-1”. Esta diferença tem implicações para outras fórmulas discutidas em capítulos posteriores. Tecnicamente, uma vez que está incluído o factor de correcção usado para o estimador da variância, seria apropriado que se usasse o símbolo do parâmetro populacional com um “chapéu”, i.e., $\hat{\sigma}^2$. Contudo a maioria dos livros de estatística define S^2 como um estimador corrigido, e não simplesmente como a variância de uma amostra.

Em geral, é difícil interpretar o significado do valor da variância porque as unidades nas quais tal valor é expresso não são as mesmas do que as das observações do conjunto de dados. Por esta razão, a raiz quadrada da variância, representada pela letra grega σ (ou S para a amostra) e chamada de desvio padrão, é a medida de dispersão que se utiliza com mais frequência.

O **desvio padrão** indica o grau de dispersão dos dados de uma amostra em torno da média amostral e é calculado pelas fórmulas:

$$\text{Desvio padrão na população: } \sigma = \sqrt{\frac{\sum (X - \mu)^2}{N}} \quad (3.15)$$

$$\text{Desvio padrão na amostra: } S = \sqrt{\frac{\sum (X - \bar{X})^2}{n - 1}} \quad (3.16)$$

O desvio padrão é particularmente útil em conjunção com a chamada distribuição normal de probabilidades (ver secção 3.2.5).

Exemplo 3.10: Considerem-se os dados do exemplo 3.8 ($n = 8$, $\bar{X} = 10,5$)

Tab.3.5: Folha de cálculo para determinar o desvio padrão para dados não agrupados

X	$(X - \bar{X})$	$(X - \bar{X})^2$
5	-5,5	30,25
8	-2,5	6,25
8	-2,5	6,25
11	0,5	0,25
11	0,5	0,25
11	0,5	0,25
14	3,5	12,25
16	5,5	30,25

Total 86,00

$$S = \sqrt{\frac{\sum (X - \bar{X})^2}{n - 1}} = \sqrt{\frac{86}{8 - 1}} = 3,5$$

A variância e o desvio padrão para dados agrupados

Para dados agrupados em uma distribuição de frequência, toma-se o ponto médio de cada classe para representar todas as medidas incluídas naquela classe.

Fórmulas:

$$\text{Variância na população: } \sigma^2 = \frac{\sum f(X_c - \mu)^2}{N} \quad (3.17)$$

$$\text{Variância na amostra: } S^2 = \frac{\sum f(X_c - \bar{X})^2}{n - 1} \quad (3.18)$$

$$\text{Desvio padrão na população: } \sigma = \sqrt{\frac{\sum f(X_c - \mu)^2}{N}} \quad (3.19)$$

$$\text{Desvio padrão na amostra: } S = \sqrt{\frac{\sum f(X_c - \bar{X})^2}{n - 1}} \quad (3.20)$$

Exemplo 3.11: Considerem-se os dados do exemplo 3.9 (tamanho médio das plantas = 145,1cm). Calcular o desvio padrão para os dados agrupados.

Tab. 3.6: Folha de cálculos para determinar o desvio padrão para dados agrupados.

Limites	Ponto médio de classe	Frequência	$X_c - \bar{X}$	$(X_c - \bar{X})^2$	$f (X_c - \bar{X})^2$
129,5 – 135,5	132,5	2	-12,6	158,76	317,52
135,5 – 141,5	138,5	7	-6,6	43,56	304,92
141,5 – 147,5	144,5	10	-0,6	0,36	3,60
147,5 – 153,5	150,5	8	5,4	29,16	233,28
153,5 – 159,5	156,5	3	11,4	129,96	389,88

$$\Sigma = 1249,2$$

$$S = \sqrt{\frac{1249,2}{29}} = 6,56$$

3.2.4 Cálculo abreviado da variância e do desvio padrão

As fórmulas anteriores são frequentemente chamadas de *fórmulas de desvios*, porque devem ser determinados, em cada caso, os desvios específicos dos valores individuais da média do grupo. Foram desenvolvidas fórmulas alternativas que são matematicamente equivalentes mas que não requerem a determinação de cada desvio. Uma vez que estas fórmulas são geralmente mais fáceis de usar nos cálculos, frequentemente são chamadas de *fórmulas de cálculo*.

Fórmulas de cálculo para dados não agrupados

$$\text{Variância na população: } \sigma^2 = \frac{\sum X^2 - N\mu^2}{N} \quad (3.21)$$

$$\text{Desvio padrão na população: } \sigma = \sqrt{\frac{\sum X^2 - N\mu^2}{N}} \quad (3.22)$$

$$\text{Variância na amostra: } S^2 = \frac{\sum X^2 - n\bar{X}^2}{n-1} \quad (3.23)$$

$$\text{Desvio padrão na amostra: } S = \sqrt{\frac{\sum X^2 - n\bar{X}^2}{n-1}} \quad (3.24)$$

Fórmulas de cálculo para dados agrupados

Variância na população:
$$\sigma^2 = \frac{\sum (f \cdot X_c^2) - N\mu^2}{N} \quad (3.25)$$

Desvio padrão na população:
$$\sigma = \sqrt{\frac{\sum (f \cdot X_c^2) - N\mu^2}{N}} \quad (3.26)$$

Variância na amostra:
$$S^2 = \frac{\sum (f \cdot X_c^2) - n\bar{X}^2}{n-1} \quad (3.27)$$

Desvio padrão na amostra:
$$S = \sqrt{\frac{\sum (f \cdot X_c^2) - n\bar{X}^2}{n-1}} \quad (3.28)$$

Nota: X_c é apenas X para dados agrupados em frequências simples (ver exemplo 3.2).

3.2.5 O uso do desvio padrão

O desvio padrão é a mais importante das medidas de dispersão, uma vez que é utilizado em conjunção com numerosos métodos de inferência estatística que serão discutidos em capítulos posteriores. Uma descrição de tal uso está além dos limites do presente capítulo. Contudo, como um exemplo do uso do desvio padrão, consideremos uma distribuição de frequência que seja simétrica e mesocúrtica. Em análise estatística, tal curva de frequência é chamada de curva normal. Para uma distribuição *normalmente distribuída*, é sabido que aproximadamente 68% das medidas estão localizadas até uma unidade de desvio padrão da média, e aproximadamente 95% das medidas estão localizadas até duas unidades de desvio padrão da média (Fig. 3.2).

$\bar{X} \pm 1S$	68% da população
$\bar{X} \pm 2S$	95% da população
$\bar{X} \pm 3S$	99% da população




Fig. 3.2: O desvio padrão e a curva normal. Dados do exemplo 3.12.

Exemplo 3.12: Foi observado que o número de alunos por turma numa escola tem distribuição normal. Se a média de alunos por turma nesta escola é de 80 e o desvio padrão é de 20 alunos, então aproximadamente 68% das turmas tem até ± 20 alunos da média, ou seja, tem entre 60 e 100 alunos. Temos também que aproximadamente 95% das turmas tem até ± 40 alunos da média, ou seja, 40 a 120 alunos e finalmente 99% das turmas tem até ± 60 alunos da média, ou seja, 20 a 140 alunos. A curva normal para esta distribuição é a da figura 3.2.

3.2.6. Dispersão absoluta e relativa. Coeficiente de variação

A variação ou dispersão real, determinada a partir do desvio padrão, ou qualquer outra medida de dispersão, é denominada **dispersão absoluta**. Entretanto, uma variação ou dispersão de 10cm, na medida de uma distância de 1 000 m, é inteiramente diferente, quanto ao efeito, da mesma variação de 10 cm em uma distância de 20 m. A medida deste efeito é proporcionada pela dispersão relativa, definida por:

$$\text{Dispersão relativa} = \frac{\text{Dispersão absoluta}}{\text{Média}} \quad (3.29)$$

Se a dispersão absoluta é o desvio padrão S e a média é a aritmética $\bar{X}$, a **dispersão relativa é denominada coeficiente de variação**, dado por:

$$\text{Coef. de Variação} = CV = \frac{S}{\bar{X}} \quad (3.30)$$

e geralmente expresso em percentagem (multiplicar CV por 100).

O Coeficiente de variação é uma medida muito útil para comparar a variabilidade em um conjunto de dados com a de outro, em situações em que a comparação directa dos desvios padrão não é conveniente ou simplesmente não faz sentido.

Note-se que o coeficiente de variação é independente das unidades de medida adoptadas. Por esta razão, é vantajoso para a comparação de distribuições cujas unidades podem ser diferentes. Uma desvantagem do coeficiente de variação é que ele deixa de ser útil quando $\bar{X}$ está próximo de zero.

Um alto Coeficiente de Variação representa um **alto grau de variabilidade, o que indica uma distribuição heterogénea dos valores da variável em torno da média.**

O coeficiente de variação toma valores entre 0 e 100%. Um CV de 0% indica ausência de variabilidade. Valores de CV próximos de 0 indicam uma variabilidade pequena enquanto que quanto mais próximos de 1 maior é a variabilidade.

Para a diferenciação do grau de variabilidade em amostras únicas toma-se 50% como referência e pode-se proceder da seguinte maneira:

Valor do coeficiente de variação	Magnitude da variação
0 %	Ausência de variação
1 – 25%	Variação relativamente pequena
26 – 50 %	Variação relativamente grande
> 50%	Grande variação

No entanto deve-se ter em conta que para muitas variáveis **existem valores padronizados do coeficiente de variação** que ao serem ultrapassados indicariam um alto grau de variabilidade. Portanto, quando se fazem análises do coeficiente de variação deve-se consultar a bibliografia para se obter informações sobre a existência de valores padronizados para a variável em estudo.

Exemplos

Nos ensaios agrícolas, para experimentos de campo, Pimentel Gomes (2000) considera os coeficientes de variação como baixos, quando inferiores a 10%, médios, quando de 10 a 20%, altos quando entre 20 e 30% e muito altos quando superiores a 30%.

Campos (1984) afirmou que nos ensaios agrícolas espera-se um coeficiente de variação entre 10 e 20 %.

Segundo Sampaio (1998), o CV é uma medida usada por pesquisadores que trabalham com a mesma variável para avaliar a precisão de cada um dos seus experimentos. Para o autor é importante que se reconheça na bibliografia os valores mais frequentes do CV para a variável que está a ser estudada.

Gil (1987) afirmou que o pesquisador deve estar atento aos valores considerados razoáveis do CV na sua área de pesquisa. Segundo ele, coeficientes de variação menores que 1% são raros em ciências biológicas, o que talvez não o seja nas ciências físicas. Muitas características biológicas apresentam coeficientes de variação na faixa entre 5 e 50%. O autor apontou ainda o uso do CV na comparação da sensibilidade de dois ou mais tratamentos medidos como indicadores alternativos de algum tratamento básico que é difícil ou mesmo impossível de se medir.

Em suma, o valor do CV varia em função da variável em estudo. Um determinado valor de CV pode ser considerado alto para uma determinada variável sendo, no entanto, baixo para uma outra.

Exemplo 3.13

Taxa de colesterol (mg/dl) de $n = 25$ homens
Média = 220mg, Desvio padrão = 20mg.

Usando a fórmula (3.30) obtém-se um coeficiente de variação de 9%, que indica um baixo grau de variabilidade da taxa de colesterol nos homens. Em termos práticos, a baixa variabilidade mostra que os indivíduos da população em estudo têm taxas de colesterol que não difere muito; significa ainda que a dispersão dos valores da taxa de colesterol em relação à média da amostra é baixa.

O coeficiente de variação é uma medida de variabilidade normalizada.

Quando se trata de comparar a dispersão de dois atributos diferentes de uma população, é conveniente **normalizar** os indicadores. Tal procedimento tem como objectivo evitar erros nas conclusões a esse respeito. O exemplo a seguir mostra um caso que ilustra esta situação.

Exemplo 3.14

Imagine uma população composta por dez crianças recém-nascidas, da qual são conhecidos os pesos (em gramas) e os comprimentos (em centímetros).

Recém nascido	1	2	3	4	5	6	7	8	9	10
Comprimento (cm)	52	48	45	49	51	54	47	50	46	51
Peso (g)	3.300	3.200	2.950	3.150	3.350	3.450	2.900	3.300	3.150	3.250

Poder-se-ia comparar as variabilidades dos pesos e dos comprimentos para saber em qual dos casos há um maior afastamento dos valores normais. Nesse sentido, seriam calculados os desvios padrões do peso e do comprimento usando-se a fórmula indicada anteriormente. Obtêm-se assim:

Desvio padrão do Peso: 171,59 g

Desvio padrão do Comprimento: 2,83 cm

A comparação dos desvios padrões dos pesos e dos comprimentos pelo seu valor absoluto supõe a ilusória conclusão de que a variabilidade dos pesos (171,59g) é muito maior que a das alturas (2,83 cm). Essa conclusão, além de totalmente incorrecta, constitui um absurdo, uma vez que estão sendo comparadas grandezas completamente diferentes (centímetro e grama).

Para resolver este problema, é utilizado o **Coeficiente de Variação** para avaliar a variabilidade dos dados.

Pela fórmula (3.30) obtêm-se os seguintes valores de coeficiente de variação:

Para o Peso: 5,4% Para o Comprimento: 5,7%

Os resultados invertem a conclusão baseada na errónea comparação das variabilidades pelos desvios padrões, uma vez que o coeficiente de variação dos comprimentos é relativamente maior que o dos pesos, o que indica uma dispersão maior em torno da média.

Exemplo 3.15

Os dados a seguir referem-se a quantidade de ácido úrico encontrada em exames laboratoriais de 25 pacientes.

2	6	4	5	9
3	7	2	6	4
4	2	3	7	3
5	3	4	8	5
4	6	5	4	7

1. Construir uma tabela de distribuição de frequências do ácido úrico tendo em conta que o valor normal é de 2 – 7 mg / dl sangue.

Ácido úrico		N.º de pacientes
< 2	Baixo	0 (0%)
2 a 7	Normal	20 (92%)
> 7	Alto	2 (8%)

Leitura interpretativa da tabela

A *maior parte* dos pacientes (92%) tem uma taxa de ácido úrico normal e *apenas* 8% tem taxa alta. Deve-se realçar também que nenhum paciente tem taxa baixa de ácido úrico.

2. Calcular a média, o desvio padrão e proceder a análise da variabilidade do ácido úrico nos pacientes (fazer a caracterização da amostra).

Resultados: Média: 4.7 mg/dl desvio padrão: 1.9 mg/dl CV: 40%

O valor da média do ácido úrico dos 25 pacientes está dentro do intervalo dos valores considerados normais. Usando o desvio padrão e a fórmula média $\pm$ desvio padrão obtém-se o intervalo de variação do ácido úrico para a maior parte dos pacientes ou seja 68% (ver tab. Fig. 3.2). O intervalo de variação é, [2.8 – 6.6], indica que 68 %, isto é, a maior parte dos pacientes apresenta uma taxa de ácido úrico que varia entre 2.8 a 6.6 e que pode ser considerada normal. O coeficiente de variação é de 40% indicando uma certa heterogeneidade na distribuição dos valores em relação à média, no entanto, isto não afecta a constatação de que o ácido úrico destes pacientes varia dentro de um intervalo de valores considerados normais.

Exercícios de análise de variabilidade

Interprete os dados que seguem:

Parâmetros da água mineral da marca LUSO (Sociedade da água Luso de Portugal, S.A.R.L.)
Fonte: Rótulo de uma garrafa.

pH $5,6 \pm 0,2$

Sílica (SiO₂): $12,4 \pm 0,5$ mg/l

Mineralização total: $41,6 \pm 1,0$ mg/L

Cálcio: $0,7 \pm 0,1$ mg/L

Sódio: $6,1 \pm 0,2$ mg/L

Magnésio: $1,5 \pm 0,1$ mg/L

Cloreto: $9,0 \pm 0,3$ mg/L

Bicarbonato: $8,0 \pm 2,0$ mg/L

GUIÃO PARA A ANÁLISE DE VARIABILIDADE

1. Fazer uma introdução genérica do assunto em análise e particularizar os objectivos bem como a finalidade da pesquisa.
2. Ler os resultados, começando pela média e decidir se ela é “boa” ou “má” tendo em conta as categorias da variável e seus valores padronizados.
3. Calcular e interpretar o intervalo de variação ($X \pm S$). Este intervalo indica o espaço ocupado por 68% dos dados (valor constante resultante da distribuição normal) e dá-nos uma ideia da variação absoluta dos dados.
4. Calcular e interpretar o coeficiente de variação ($CV (\%) = \frac{S}{X} \times 100$). Este valor indica a variação relativa e tem a seguinte interpretação:

CV	Significado
0 %	Ausência de variação
1 – 25%	Variação relativamente pequena
26 – 50%	Variação relativamente grande
Maior que 50%	Grande variação

Caso a variável tenha um coeficiente de variação pré definido este deverá ser usado como critério de análise da variação relativa, i.e, o CV da amostra em análise é comparado com o CV padronizado. Se o CV da amostra for superior ao CV padronizado conclui-se que houve grande variabilidade.